

Teste Power BI

Case ACT

Consultor em Power BI

Modelagem Dimensional & Dashboards Interativos

Apresentação do projeto de transformação de dados
e desenvolvimento de dashboards analíticos

Desenvolvido por Wagner Inacio

Descrição do Projeto

Este projeto representa um teste de entrevista para a posição de **Consultor em Power BI** na ACT. O objetivo é demonstrar a habilidade de transformar dados brutos de uma planilha Excel em um modelo de dados estruturado, seguindo as melhores práticas de modelagem dimensional para Business Intelligence.

O que foi feito

- Processamento dos dados originais em Excel usando Python (Pandas)
- Criação de um esquema estrela (Star Schema) com tabelas dimensão e fato
- Desenvolvimento de dashboards interativos no Power BI
- Criação de medidas DAX para análises comparativas e KPIs

Estrutura dos Dados


Os dados originais foram normalizados e separados em:

Tabela	Descrição
Dim_Tempo	Data de referência, ano, mês, nome do mês
Dim_Local	UF, cidade, DDD
Dim_Produto	Produto, plano, tecnologia, segmento
Dim_Canal	Canais de venda
Dim_Indicador	Indicadores de nível 1 e 2
Dim_Cenario	Origem e cenário dos dados
Fato_Vendas	Valores de vendas com chaves estrangeiras

Por que a Modelagem Dimensional?

- **Facilita Análises e Relatórios** — Dimensões fornecem contexto descritivo, permitindo filtros, agrupamentos e drill-downs intuitivos.
- **Reduz Redundância** — Informações descritivas armazenadas uma vez, economizando espaço e facilitando manutenção.
- **Melhora Performance** — Consultas analíticas mais rápidas com junções simples. Power BI otimiza consultas em esquemas estrela.
- **Suporte a Agregações** — Tabela fato com medidas numéricas permite cálculos como somas e médias. Dimensões suportam hierarquias.
- **Manutenibilidade e Escalabilidade** — Mudanças em descrições afetam apenas a dimensão correspondente. Fácil adição de novas dimensões.
- **Compatibilidade com BI** — Power BI e outras ferramentas são otimizadas para modelos dimensionais.


Modelo de Dados (Star Schema)



Modelo de relacionamento no Power BI — Esquema Estrela


Dashboard: Visão Geral

Painel principal com KPIs de Vendas Brutas (R\$ 41,7 Mi), Vendas Líquidas (R\$ 31,1 Mi), Gross (R\$ 30,8 Mi), Churn (R\$ 14,1 Mi), Netadds (R\$ 16,8 Mi) e Base EOP (R\$ 656,7 Mi). Inclui gráfico de evolução dos últimos 13 meses e comparativo 2024 vs 2023. Filtros por Ano, Mês, UF, Cidade, Canal, Tecnologia e Plano.




Dashboard: Análise por Canal

Ranking dos canais de venda com métricas de Venda Bruta, Gross, Churn e variação percentual mensal. Gráfico de barras com variação Gross % por canal.



Dashboard: Análise de Região

Análise geográfica com gráficos de Gross e Churn por cidade e scatter plot. Tabela detalhada com métricas por cidade: São Paulo lidera com R\$ 23,6 Mi em Venda Bruta, seguida por Rio de Janeiro com R\$ 12,1 Mi.



Dashboard: Mix Comercial

Cruzamento de Canal x Plano e Canal x Tecnologia (FTTC e FTTH). Visão matricial detalhada com valores de Gross e Churn Total por combinação. Agent Sales lidera com R\$ 13,5 Mi em Gross total.

Mix Comercial

Visão Geral

Canal

Região

Mix

Cancelamento

Churn

ANO

MÊS

UF

CIDADE

CANAL

TECNOLOGIA

PLANO

Canal x Plano														
Plano	BANDA LARGA FIXA 3 MEGA		LIVE TIM		LIVE TIM 1 GIGA		LIVE TIM 100 MEGA		LIVE TIM 1000 MEGA		LIVE TIM 15 MEGA		LIVE TIM 150 MEGA	
Canal	Gross	Churn Total	Gross	Churn Total	Gross	Churn Total	Gross	Churn Total	Gross	Churn Total	Gross	Churn Total	Gross	Churn To
AGENT SALES			R\$ 5.735.436	R\$ 3.460.884	R\$ 84		R\$ 806.106	R\$ 80.892				R\$ 336	R\$ 484.932	R\$ 22.0
CALL CENTER			R\$ 378	R\$ 42										
CRC			R\$ 47.166	R\$ 23.646			R\$ 1.092	R\$ 126					R\$ 1.092	R\$
DIGITAL SALES			R\$ 3.017.364	R\$ 1.586.802			R\$ 137.130	R\$ 9.996			R\$ 42	R\$ 378	R\$ 63.630	R\$ 3.4
LOJA PROPRIA			R\$ 1.848	R\$ 546			R\$ 1.344						R\$ 546	
LOJAS			R\$ 6.804	R\$ 12.222										
NÃO IDENTIFICADO			R\$ 9.660	R\$ 9.114			R\$ 420						R\$ 252	
Total	R\$ 84	R\$ 42	R\$ 14.469.756	R\$ 8.435.658	R\$ 84		R\$ 1.177.722	R\$ 103.740	R\$ 84		R\$ 84	R\$ 42	R\$ 1.470	R\$ 676.998

Canal x Tecnologia							
Tecnologia	FTTC		FTTH		Total		
Canal	Gross	Churn Total	Gross	Churn Total	Gross	Churn Total	
AGENT SALES	R\$ 12.193.146	R\$ 6.065.094	R\$ 1.295.196	R\$ 102.942	R\$ 13.488.342	R\$ 6.168.036	
CALL CENTER	R\$ 714	R\$ 336			R\$ 714	R\$ 336	
CRC	R\$ 84.756	R\$ 35.532	R\$ 2.268	R\$ 210	R\$ 87.024	R\$ 35.742	
DIGITAL SALES	R\$ 5.940.984	R\$ 2.517.816	R\$ 192.150	R\$ 13.020	R\$ 6.133.134	R\$ 2.530.836	
LOJA PROPRIA	R\$ 12.768	R\$ 1.512	R\$ 1.974	R\$ 42	R\$ 14.742	R\$ 1.554	
LOJAS	R\$ 8.358	R\$ 15.288			R\$ 8.358	R\$ 15.288	
NÃO IDENTIFICADO	R\$ 17.220	R\$ 11.592	R\$ 672		R\$ 17.892	R\$ 11.592	
Total	R\$ 29.005.368	R\$ 13.954.500	R\$ 1.843.758	R\$ 137.256	R\$ 30.849.126	R\$ 14.091.756	

Dashboard: Cancelamento

Análise de cancelamentos por tipo: Cliente (R\$ 1,2 Mi), Comercial (R\$ 5,5 Mi), Não Classificado (R\$ 1,3 Mi), Técnico (R\$ 1,4 Mi), Técnico/Comercial (R\$ 464 Mil). Total de R\$ 10,6 Mi. Tabela de detalhes com percentual por combinação de canal, tecnologia e cidade.

Cancelamento

Visão Geral

Canal

Região

Mix

Cancelamento

Churn

ANO

MÊS

UF

CIDADE

CANAL

TECNOLOGIA

PLANO

Cancelamento Cliente

Cancelamento Comercial

Cancelamento não Classificado

Cancelamento Técnico

Cancelamento Técnico/Comercial

Cancelamento Total

R\$ 1,2 Mi

R\$ 5,5 Mi

R\$ 1,3 Mi

R\$ 1,4 Mi

R\$ 464,3 Mil


R\$ 10,6 Mi

Tabela de detalhe

Canal	Tecnologia	Plano	Cidade	UF	Cancelamento Total	%GT Cancelamento Total
AGENT SALES	FTTC	LIVE TIM	SAO PAULO	SP	R\$ 1.742.832	16,44%
AGENT SALES	FTTC	LIVE TIM MULTI	SAO PAULO	SP	R\$ 1.396.626	13,17%
AGENT SALES	FTTC	LIVE TIM	RIO DE JANEIRO	RJ	R\$ 509.334	4,80%
DIGITAL SALES	FTTC	LIVE TIM	SAO PAULO	SP	R\$ 457.842	4,32%
TELESALES IN	FTTC	LIVE TIM	SAO PAULO	SP	R\$ 391.188	3,69%
DIGITAL SALES	FTTC	LIVE TIM	RIO DE JANEIRO	RJ	R\$ 349.146	3,29%
AGENT SALES	FTTC	LIVE TIM 60 MEGA	SAO PAULO	SP	R\$ 332.346	3,13%
TELESALES IN	FTTC	LIVE TIM	RIO DE JANEIRO	RJ	R\$ 332.052	3,13%
AGENT SALES	FTTC	LIVE TIM MULTI	RIO DE JANEIRO	RJ	R\$ 326.886	3,08%
DIGITAL SALES	FTTC	LIVE TIM MULTI	SAO PAULO	SP	R\$ 301.308	2,84%
TELESALES OUT	FTTC	LIVE TIM	SAO PAULO	SP	R\$ 248.094	2,34%
TELESALES IN	FTTC	LIVE TIM MULTI	SAO PAULO	SP	R\$ 236.964	2,23%
AGENT SALES	FTTH	LIVE TIM 100 MEGA	SAO PAULO	SP	R\$ 207.858	1,96%
DIGITAL SALES	FTTC	LIVE TIM MULTI	RIO DE JANEIRO	RJ	R\$ 200.424	1,89%
TELESALES OUT	FTTC	LIVE TIM	RIO DE JANEIRO	RJ	R\$ 197.694	1,86%
TELESALES IN	FTTC	LIVE TIM MULTI	RIO DE JANEIRO	RJ	R\$ 155.640	1,47%
Total					R\$ 10.604.034	100,00%

Dashboard: Churn

Análise de Churn com comparativo 2024 (R\$ 2,6 Mi) vs 2023 (R\$ 3,6 Mi), queda de -25,9%. Churn Voluntário (R\$ 9,6 Mi / 67,98%) vs Involuntário (R\$ 4,5 Mi / 32,02%). Evolução mensal com pico em maio/junho.



Código Python — Tratamento de Dados

O script abaixo foi desenvolvido em Python utilizando a biblioteca **Pandas** para realizar a transformação dos dados brutos do Excel em um modelo dimensional (Star Schema). O código cria as tabelas de dimensão e a tabela fato, exportando-as como arquivos CSV.

```
import pandas as pd

df = pd.read_excel('data/dados_ACT.xlsx')
df['DT_REF_MES'] = pd.to_datetime(df['DT_REF_MES'], origin='1899-12-30', unit='D')

def create_dim(df, cols, id_col):
    dim = df[cols].drop_duplicates().reset_index(drop=True)
    dim[id_col] = dim.index + 1
    return dim[[id_col] + cols]

dim_tempo = create_dim(df, ['DT_REF_MES'], 'ID_Tempo')
dim_tempo['Ano'] = dim_tempo['DT_REF_MES'].dt.year
dim_tempo['Mes'] = dim_tempo['DT_REF_MES'].dt.month
dim_tempo['Mes_Nome'] = dim_tempo['DT_REF_MES'].dt.strftime('%B')
dim_tempo = dim_tempo[['ID_Tempo', 'DT_REF_MES', 'Ano', 'Mes', 'Mes_Nome']]

dim_local = create_dim(df, ['UF', 'CIDADE', 'DDD'], 'ID_Local')
dim_produto = create_dim(df, ['PRODUTO', 'PLANO', 'TECNOLOGIA', 'SEGMENTO'], 'ID_Produto')
dim_canal = create_dim(df, ['CANAL'], 'ID_Canal')
dim_indicador = create_dim(df, ['INDICADOR_N1', 'INDICADOR_N2'], 'ID_Indicador')
dim_cenario = create_dim(df, ['ORIGEM', 'CENARIO'], 'ID_Cenario')

fato = df.copy()
fato = fato.merge(dim_tempo[['ID_Tempo', 'DT_REF_MES']], on='DT_REF_MES', how='left')
fato = fato.merge(dim_local[['ID_Local', 'UF', 'CIDADE', 'DDD']], on=['UF', 'CIDADE', 'DDD'], how='left')
fato = fato.merge(dim_produto[['ID_Produto', 'PRODUTO', 'PLANO', 'TECNOLOGIA', 'SEGMENTO']], on=['PRODUTO', 'PLANO', 'TECNOLOGIA', 'SEGMENTO'], how='left')
fato = fato.merge(dim_canal[['ID_Canal', 'CANAL']], on='CANAL', how='left')
fato = fato.merge(dim_indicador[['ID_Indicador', 'INDICADOR_N1', 'INDICADOR_N2']], on=['INDICADOR_N1', 'INDICADOR_N2'], how='left')
fato = fato.merge(dim_cenario[['ID_Cenario', 'ORIGEM', 'CENARIO']], on=['ORIGEM', 'CENARIO'], how='left')
fato = fato[['ID_Tempo', 'ID_Local', 'ID_Produto', 'ID_Canal', 'ID_Indicador', 'ID_Cenario', 'valor']]

dims = {
    'Dim_Tempo.csv': dim_tempo,
    'Dim_Local.csv': dim_local,
    'Dim_Produto.csv': dim_produto,
    'Dim_Canal.csv': dim_canal,
    'Dim_Indicador.csv': dim_indicador,
    'Dim_Cenario.csv': dim_cenario
}

for file, data in dims.items():
    data.to_csv(f'dimensions/{file}', index=False)
fato.to_csv('facts/Fato_Vendas.csv', index=False)
```

Script estrutura_dados.py — Processamento e modelagem dimensional

Estrutura do Projeto

```
/
├── data/
│   ├── dados_ACT.xlsx
│   └── dimensions/
│       ├── Dim_Canal.csv
│       ├── Dim_Cenario.csv
│       ├── Dim_Indicador.csv
│       ├── Dim_Local.csv
│       ├── Dim_Produto.csv
│       └── Dim_Tempo.csv
├── facts/
│   └── Fato_Vendas.csv
├── src/
│   └── estrutura_dados.py
├── Case_ACT.pbix
└── README.md
```

Arquivos Entregues

- **Case_ACT.pbix** — Dashboard Power BI com modelo de dados e visualizações interativas
- **Apresentação.pdf** — Apresentação do projeto com explicação dos dashboards